

Informe

Perfil transcriptómico diferencial asociado a metástasis en el modelo MMTV-ErbB2 mediante análisis exploratorio de datos

Por *Ronald Rivas*

Introducción

El análisis de datos transcriptómicos se ha convertido en una de las metodologías fundamentales para comprender los cambios moleculares asociados a condiciones fisiopatológicas como el cáncer. A través de técnicas de RNA-Seq, es posible cuantificar miles de genes simultáneamente y determinar diferencias en su expresión entre fenotipos biológicos contrastantes [1][2]. En este estudio se desarrolla un análisis exploratorio de datos (EDA) sobre el dataset GSE223351, el cual contiene datos de expresión génica en un modelo murino de cáncer de mama MMTV-ErbB2, comparando muestras con fenotipo control frente a metástasis. Se realiza la preparación del dataset mediante normalización TPM (Transcripts Per Million), filtrado por varianza, análisis estadístico con prueba t y visualización mediante volcano plot y heatmap, con el fin de identificar genes diferencialmente expresados que puedan estar implicados en la progresión tumoral y capacidad metastásica [2].

La hipótesis de trabajo plantea que existe una expresión diferencial significativamente alterada en genes asociados a procesos metastásicos en el modelo MMTV-ErbB2, observable a partir del análisis exploratorio y pruebas estadísticas aplicadas al dataset. Este enfoque es respaldado por evidencia previa que señala que ErbB2/HER2 promueve proliferación celular, invasión y mal pronóstico en cáncer de mama [3]. En consecuencia, el presente estudio busca aportar una caracterización temprana de los patrones moleculares metastásicos, como base para futuros análisis funcionales (vía KEGG/GO) que permitan establecer rutas biológicas y biomarcadores potenciales para diagnóstico y terapias dirigidas [3][4].

Metodología

El análisis se llevó a cabo empleando herramientas de ciencia de datos en Python para caracterizar diferencias en la expresión génica entre muestras de cáncer de mama metastásico y controles, utilizando el dataset GSE223351 obtenido del repositorio NCBI GEO [1]. El flujo metodológico siguió lineamientos estándares en transcriptómica computacional para análisis de RNA-Seq [2][4].

Cada etapa del procedimiento se describe a continuación:

- **Obtención de datos**

Se descargó el archivo *raw count matrix* en formato .xlsx asociado al identificador GEO GSE223351, correspondiente a un estudio con seis muestras de expresión génica (tres controles y tres metástasis).

Herramientas: *Requests library* en Python.

- **Carga y estructuración del dataset**

Se importaron los datos en un DataFrame utilizando **Pandas**, asegurando nombres únicos

para los genes mediante indexación y eliminación de columnas no informativas.

Herramientas: Pandas.

- **Normalización de datos – TPM**

Como el conteo de lecturas puede variar entre muestras, se utilizó la normalización Transcripts Per Million (TPM), seguida de una transformación logarítmica base 2 para estabilizar la varianza en abundancias relativas [3].

Herramientas: NumPy.

Fórmula aplicada:

$$TPM = \frac{Count}{LibrarySize} \times 10^6 \quad ; \quad \log_2(TPM + 1)$$

- **Filtrado por varianza**

Se eliminaron genes sin variabilidad entre muestras, ya que no aportan información para el análisis estadístico posterior.

Herramientas: Estadística descriptiva.

- **Prueba estadística de hipótesis**

Se realizó un t-test bilateral independiente para contrastar expresión entre grupos:

H0: No existe diferencia en la expresión entre condiciones

H1: Existen diferencias expresivas entre condiciones

Herramientas: `scipy.stats.ttest_ind`.

- **Corrección por comparaciones múltiples**

Para controlar el error tipo I generado por análisis génico masivo, se aplicó el ajuste FDR Benjamini–Hochberg a los p-values [5].

Herramientas: `statsmodels.stats.multitest.multipletests`.

- **Clasificación de genes diferencialmente expresados**

Se establecieron umbrales estrictos para identificar significancia biológica y estadística:

$$|\log_2FC| \geq 1 \rightarrow \text{cambio expresivo relevante}$$
$$FDR \leq 0.05$$

- **Visualización de resultados**

Se generaron dos gráficos analíticos:

Volcano Plot:

Para evaluación simultánea de amplitud de cambio ($\log_2FC$) y significancia estadística ($-\log_{10} FDR$).

Heatmap:

Para observar patrones de agrupamiento entre genes más significativos

Herramientas: Matplotlib, Seaborn.

Resultados

El análisis exploratorio y estadístico permitió identificar patrones diferenciales de expresión génica entre los tres modelos de Control y los tres modelos de Metástasis. Tras la normalización TPM con transformación $\log_2$, el filtrado por varianza redujo el conjunto inicial de genes a aquellos que aportan información discriminativa entre los grupos comparativos [4][5].

Se aplicó una prueba t-test independiente para evaluar la significancia estadística por gen. En combinación con la corrección FDR (Benjamini-Hochberg), se obtuvieron valores ajustados (Adj-p) que permiten establecer un marco riguroso para la detección de expresión diferencial. Utilizando un umbral de:


$$\begin{aligned} |\log_2FC| &> 1 \\ \text{Adj-p} &< 0.05 \end{aligned}$$

Se clasificaron los genes como:

- **Sobreexpresados** en metástasis
- **Subexpresados** en metástasis
- **No significativos (NS)**

La Figura 1 (Volcano Plot) muestra la distribución global de la significancia estadística y el cambio de expresión. Se observa una proporción notoria de genes con sobreexpresión asociada al fenotipo metastásico, lo que respalda la hipótesis planteada sobre la existencia de rutas moleculares diferencialmente activas en la metástasis.

Figura 1. Volcano plot de expresión diferencial entre condiciones.



Asimismo, se seleccionaron los 20 genes más significativos, priorizando aquellos con mayor evidencia estadística (menor Adj-p). Estos conforman un panel con alto potencial para investigación biomarcadora y funcional en cáncer de mama metastásico.


Tabla 1. Genes diferencialmente expresados más relevantes

Genes	log2FC	p_values	Adj_p	Clasificación
<i>Mira</i>	3.006858	5.22E-08	0.001002	Sobreexpresado
<i>Hoxa7</i>	2.876389	2.09E-07	0.002009	Sobreexpresado
<i>Hgfac</i>	6.779529	4.28E-07	0.002050	Sobreexpresado
<i>Tspan17</i>	-3.709279	3.85E-07	0.002050	Subexpresado
<i>3300005D01Rik</i>	2.633463	1.46E-06	0.005587	Sobreexpresado
<i>Prox2</i>	1.567023	2.02E-06	0.006444	Sobreexpresado
<i>Fam171a1</i>	3.459737	2.94E-06	0.007051	Sobreexpresado
<i>Pon3</i>	-4.864964	2.84E-06	0.007051	Subexpresado
<i>Sgsm1</i>	-2.604117	3.95E-06	0.007584	Subexpresado
<i>Iqgap1</i>	-2.099792	6.85E-06	0.009384	Subexpresado
<i>Tchh</i>	2.094165	6.79E-06	0.009384	Sobreexpresado

<i>Itm2a</i>	-1.610476	5.74E-06	0.009384	Subexpresado
<i>Mark3</i>	1.315800	8.94E-06	0.009531	Sobreexpresado
<i>Gspt2</i>	3.534040	8.05E-06	0.009531	Sobreexpresado
<i>B4galt4</i>	2.416575	8.59E-06	0.009531	Sobreexpresado
<i>Gsto2</i>	3.688647	1.00E-05	0.010101	Sobreexpresado
<i>Bdkrb2</i>	3.433325	1.08E-05	0.010390	Sobreexpresado

Con el fin de evaluar la coherencia global del perfil de expresión, se realizó una visualización tipo heatmap con clustering jerárquico, donde se aprecia una clara separación entre los grupos experimentales. Este resultado sugiere que los genes detectados poseen un patrón de expresión consistente, útil para caracterizar e incluso predecir el estado metastásico.

Figura 2. Heatmap de los 20 genes más diferencialmente expresados.



Discusión

Los resultados obtenidos en el análisis transcriptómico sugieren que existe un conjunto significativo de genes diferencialmente expresados entre los grupos Metástasis y Control, lo que respalda la hipótesis propuesta inicialmente. La identificación de genes sobreexpresados en metástasis podría estar relacionada con rutas de señalización oncogénica, proliferación celular y

evasión de mecanismos inmunológicos, procesos previamente descritos en la progresión tumoral del cáncer de mama [1][3].

La visualización mediante volcano plot permitió una interpretación clara del balance entre magnitud del cambio ($\log_2FC$) y relevancia estadística (FDR), priorizando biomarcadores potenciales para estudio posterior. El heatmap confirmó patrones de agrupamiento coherentes con el estado clínico de las muestras, lo cual sugiere que el perfil de expresión puede discriminar adecuadamente entre condiciones biológicas, evidenciando un impacto significativo de la metástasis en la regulación génica global.

Además, el pipeline aplicado demostró que un EDA biológico correctamente implementado puede facilitar la transición hacia análisis funcionales, como enriquecimiento de vías y ontologías, permitiendo avanzar hacia interpretaciones moleculares más robustas del fenómeno metastásico [2][4][5]. Sin embargo, deben considerarse limitaciones, como el tamaño muestral reducido y la ausencia de validación experimental independiente. Futuras investigaciones deberían incorporar análisis integrativos multi-ómicos y validación in vitro/in vivo para confirmar el rol de los genes candidatos.

Conclusiones

- Se logró preparar, procesar y analizar un dataset transcriptómico real desde su adquisición hasta la generación de resultados visuales interpretables.
- La normalización TPM y filtrado por varianza permitieron construir una matriz de expresión robusta y lista para análisis estadístico.
- La prueba estadística por gen reveló diferencias significativas en la expresión entre el grupo Metástasis y Control.
- Las representaciones gráficas (volcano plot y heatmap) confirmaron patrones de expresión consistentes con el comportamiento clínico de las muestras.
- El estudio evidencia que el análisis exploratorio de datos es crucial en transcriptómica para identificar posibles biomarcadores y rutas alteradas asociadas con la progresión del cáncer.
- Se generó un pipeline reproducible en Python, aplicable a otros estudios de RNA-Seq.
- La hipótesis se apoya en los resultados obtenidos: la metástasis se asocia con cambios significativos en la expresión génica, detectables mediante EDA.

Recomendaciones

- Ampliar el número de muestras y tipos tumorales.
- Integrar datos clínicos para análisis correlacional.
- Realizar validación experimental de los genes más relevantes.
- Añadir enriquecimiento funcional GO/KEGG para interpretación biológica más profunda.

Referencias

- [1] M. A. Dillies et al., “A comprehensive evaluation of normalization methods for Illumina high-throughput RNA sequencing data analysis,” *Briefings in Bioinformatics*, vol. 14, no. 6, pp. 671–683, 2013.
- [2] J. Robinson and McCarthy K., “A scaling normalization method and differential expression analysis for RNA-Seq data,” *Genome Biology*, vol. 11, no. 3, 2010.
- [3] E. Wagner, K. Kin y M. Lynch, “Normalization methods for RNA-seq data: TPM vs FPKM/RPKM,” *RNA-Seq Blog*, 2022.
- [4] J. Zhao, T. Ye, W. Stanton, “When to use TPM, FPKM, RPKM or raw counts in RNA-Seq,” *RNA-Seq Blog*, 2020.
- [5] P. Pertea, “RNA-seq: transcripts per million (TPM), RPKM, FPKM,” *Bioinformatics Tutorial*, 2021.

Anexos

[Script Proyecto Sena.ipynb](#)